

応用数学レポート

2024/5/15

1 線形代数

1.1 行列

行列とは、ベクトルを並べたもの。連立方程式の研究の中から生まれた。例えば、連立法定式 1 は、行列 A , ベクトル \vec{b}, \vec{c} を用いて、式 2 のように $A\vec{x} = \vec{b}$ と整形できる。

$$\begin{cases} x_1 + 2x_2 = 3 \\ 2x_1 + 5x_2 = 5 \end{cases} \quad (1)$$

$$\begin{pmatrix} 1 & 2 \\ 2 & 5 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 3 \\ 5 \end{pmatrix} \quad (2)$$

また、行基本変形として、行列は以下の 3 つの変形ができる。

1. i 行目を c 倍する
2. s 行目に t 行目の c 倍を加える
3. p 行目と q 行目を入れ替える

1.2 単位行列と逆行列

単位行列 I とは、ある行列とかけても相手が変わらない行列のことであり、式 3 のように表される。すなわち、相手の行列を A とすれば、式 4 の関係になる。

$$I = \begin{pmatrix} 1 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \end{pmatrix} \quad (3)$$

$$AI = IA = A \quad (4)$$

行列 A の逆行列 A^{-1} とは、 A とかけることで単位行列となる逆数のようなものであり、式 5 の関係になる。

$$AA^{-1} = A^{-1}A = I \quad (5)$$

逆行列の求め方は掃き出し法などがあり、逆行列が存在する条件として行列式が 0 でないということが挙げられる。

1.3 固有値と固有ベクトル

行列 A に対して、式 6 のようなベクトル \vec{v} とスカラー値 λ があったとすると、 \vec{v}, λ をそれぞれ行列 A に対する固有ベクトル、固有値という。

$$A\vec{v} = \lambda\vec{v} \quad (6)$$

1.4 固有値分解

正方行列 A に対し、固有値 $\lambda_1, \lambda_2, \dots, \lambda_r$ と固有ベクトル $\vec{v}_1, \vec{v}_2, \dots, \vec{v}_r$ を持ったとする。この固有値を対角線上に並べそれ以外の成分を 0 とした行列 Λ (式 7) と、固有ベクトルを並べた行列 V (式 8) を用意したとき、式 9 の関係となる。

$$\Lambda = \begin{pmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_r \end{pmatrix} \quad (7)$$

$$V = (\vec{v}_1 \quad \vec{v}_2 \quad \cdots \quad \vec{v}_r) \quad (8)$$

$$AV = V\Lambda \quad (9)$$

すなわち、式 10 と変形できる。

$$A = V\Lambda V^{-1} \quad (10)$$

このように、正方行列 A を式 10 のように 3 つの行列の積に変換することを固有値分解という。固有値分解によって、行列の累乗の計算が容易になる等の利点があり、実際に行列 A の k 乗は式 11 と表せる。

$$A^k = V\Lambda^k V^{-1} = V \begin{pmatrix} \lambda_1^k & 0 & \cdots & 0 \\ 0 & \lambda_2^k & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_r^k \end{pmatrix} V^{-1} \quad (11)$$

1.4.1 問題 (講義資料より一部変更して抜粋)

$\begin{pmatrix} 4 & 1 \\ 0 & 6 \end{pmatrix}$ を固有値分解せよ

$$A\vec{x} = \lambda\vec{x}$$

$$(A - \lambda I)\vec{x} = 0$$

ここで、 $\vec{x} \neq \vec{0}$ から、 $A - \lambda I$ は逆行列を持つてはいけない、すなわち、 $|A - \lambda I| = 0$ であることから、

$$\begin{vmatrix} 4 - \lambda & 1 \\ 0 & 6 - \lambda \end{vmatrix} = 0 \\ (4 - \lambda)(6 - \lambda) = 0 \\ \lambda = 4, 6$$

$\lambda = 4$ のとき、

$$\begin{pmatrix} 4 & 1 \\ 0 & 6 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = 4 \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \text{ よって、 } x_2 = 0$$

$\lambda = 6$ のとき、

$$\begin{pmatrix} 4 & 1 \\ 0 & 6 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = 6 \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \text{ よって、 } 2x_1 = x_2$$

したがって、

$$\lambda = 4 \text{ のとき } \vec{x} = \begin{pmatrix} 1 \\ 0 \end{pmatrix} \text{ の定数倍}$$

$$\lambda = 6 \text{ のとき } \vec{x} = \begin{pmatrix} 1 \\ 2 \end{pmatrix} \text{ の定数倍}$$

つまり、

$$\begin{pmatrix} 4 & 1 \\ 0 & 6 \end{pmatrix} = \begin{pmatrix} 1 & 1 \\ 0 & 2 \end{pmatrix} \begin{pmatrix} 4 & 0 \\ 0 & 6 \end{pmatrix} \begin{pmatrix} 1 & 1 \\ 0 & 2 \end{pmatrix}^{-1}$$

$$\begin{pmatrix} 4 & 1 \\ 0 & 6 \end{pmatrix} = \begin{pmatrix} 1 & 1 \\ 0 & 2 \end{pmatrix} \begin{pmatrix} 4 & 0 \\ 0 & 6 \end{pmatrix} \begin{pmatrix} 1 & -1/2 \\ 0 & 1/2 \end{pmatrix}$$

1.5 特異値分解

正方行列以外で固有値分解と似たようなことができるように、特異値分解がある。以下、特異値分解について述べる。

正方行列でない行列 M に対して、式 12,13 を満たす単位ベクトル \vec{u}, \vec{v} とスカラー値 σ があったとする。

$$M\vec{v} = \sigma\vec{u} \quad (12)$$

$$M^T\vec{u} = \sigma\vec{v} \quad (13)$$

このとき、 \vec{u}, \vec{v} を行列 M に対する特異ベクトル、 σ を特異値という。

さらに、それぞれ r 個の特異ベクトルと特異値をもっているとする、すなわち、特異値 $\sigma_1, \sigma_2, \dots, \sigma_r$ と特異ベクトル $\vec{u}_1, \vec{u}_2, \dots, \vec{u}_r, \vec{v}_1, \vec{v}_2, \dots, \vec{v}_r$ を持ったとする。特異値を対角線上に並べそれ以外の成分を 0 とした行列 S (式 14) と特異ベクトル \vec{u}, \vec{v} をそれぞれ並べた行列 U (式 15), V (式 16) を用意したとき、式 12 から式 17 の関係となる。

$$S = \begin{pmatrix} \sigma_1 & 0 & \cdots & 0 \\ 0 & \sigma_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma_r \end{pmatrix} \quad (14)$$

$$U = (\vec{u}_1 \quad \vec{u}_2 \quad \cdots \quad \vec{u}_r) \quad (15)$$

$$V = (\vec{v}_1 \quad \vec{v}_2 \quad \cdots \quad \vec{v}_r) \quad (16)$$

$$M = USV^{-1} \quad (17)$$

式 17 は、行列 M を固有値分解のように 3 つの行列の積に変換できっており、この変換を特異値分解という。

一方、式 13 から、式 18 の関係も導かれる。

$$M^T = VS^T U^{-1} \quad (18)$$

そのため、式 17,18 より、式 19 が導かれる。

$$MM^T = USV^{-1}VS^T U^{-1} = USS^T U^{-1} \quad (19)$$

すなわち、 MM^T を固有値分解すれば、その左特異ベクトル U と特異値の 2 乗が求められることがわかる。同様に、 $M^T M$ を固有値分解すれば、その右特異ベクトル V と特異値の 2 乗を求められる。

特異値分解は、画像データ量を小さくするといった前処理で使われている。

1.5.1 問題（講義資料より抜粋）

$\begin{pmatrix} 1 & 2 & 3 \\ 3 & 2 & 1 \end{pmatrix}$ を特異値分解せよ

$$MM^T = \begin{pmatrix} 1 & 2 & 3 \\ 3 & 2 & 1 \end{pmatrix} \begin{pmatrix} 1 & 3 \\ 2 & 2 \\ 3 & 1 \end{pmatrix} = \begin{pmatrix} 14 & 10 \\ 10 & 14 \end{pmatrix}$$

これを固有値分解する。

$$\begin{vmatrix} 14 - \lambda & 10 \\ 10 & 14 - \lambda \end{vmatrix} = 0$$

$$(14 - \lambda)^2 - 10^2 = 0$$

$$(24 - \lambda)(4 - \lambda) = 0$$

$$\lambda = 24, 4$$

$$\lambda = 24 \text{ のとき } \begin{pmatrix} 14 & 10 \\ 10 & 14 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = 24 \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \text{ より } \vec{x} = \begin{pmatrix} 1/\sqrt{2} \\ 1/\sqrt{2} \end{pmatrix}$$

$$\lambda = 4 \text{ のとき } \begin{pmatrix} 14 & 10 \\ 10 & 14 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = 4 \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \text{ より } \vec{x} = \begin{pmatrix} -1/\sqrt{2} \\ 1/\sqrt{2} \end{pmatrix}$$

$$\text{よって } \begin{pmatrix} 14 & 10 \\ 10 & 14 \end{pmatrix} = \begin{pmatrix} 1/\sqrt{2} & -1/\sqrt{2} \\ 1/\sqrt{2} & 1/\sqrt{2} \end{pmatrix} \begin{pmatrix} 24 & 0 \\ 0 & 4 \end{pmatrix} \begin{pmatrix} 1/\sqrt{2} & -1/\sqrt{2} \\ 1/\sqrt{2} & 1/\sqrt{2} \end{pmatrix}^{-1}$$

同様に、

$$M^T M = \begin{pmatrix} 1 & 3 \\ 2 & 2 \\ 3 & 1 \end{pmatrix} \begin{pmatrix} 1 & 2 & 3 \\ 3 & 2 & 1 \end{pmatrix} = \begin{pmatrix} 10 & 8 & 6 \\ 8 & 8 & 8 \\ 6 & 8 & 10 \end{pmatrix}$$

を固有値分解する。

$$\begin{vmatrix} 10-\lambda & 8 & 6 \\ 8 & 8-\lambda & 8 \\ 6 & 8 & 10-\lambda \end{vmatrix} = 0$$

$$\lambda(24-\lambda)(4-\lambda) = 0$$

$$\lambda = 24, 4, 0$$

$$\lambda = 24 \text{ のとき } \begin{pmatrix} 10 & 8 & 6 \\ 8 & 8 & 8 \\ 6 & 8 & 10 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = 24 \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} \text{ より } \vec{x} = \begin{pmatrix} 1/\sqrt{3} \\ 1/\sqrt{3} \\ 1/\sqrt{3} \end{pmatrix}$$

$$\lambda = 4 \text{ のとき } \begin{pmatrix} 10 & 8 & 6 \\ 8 & 8 & 8 \\ 6 & 8 & 10 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = 4 \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} \text{ より } \vec{x} = \begin{pmatrix} 1/\sqrt{2} \\ 0 \\ -1/\sqrt{2} \end{pmatrix}$$

$$\lambda = 0 \text{ のとき } \begin{pmatrix} 10 & 8 & 6 \\ 8 & 8 & 8 \\ 6 & 8 & 10 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = 0 \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} \text{ より } \vec{x} = \begin{pmatrix} 1/\sqrt{6} \\ -2/\sqrt{6} \\ 1/\sqrt{6} \end{pmatrix}$$

$$\text{よって } \begin{pmatrix} 10 & 8 & 6 \\ 8 & 8 & 8 \\ 6 & 8 & 10 \end{pmatrix} = \begin{pmatrix} 1/\sqrt{3} & 1/\sqrt{2} & 1/\sqrt{6} \\ 1/\sqrt{3} & 0 & -2/\sqrt{6} \\ 1/\sqrt{3} & -1/\sqrt{2} & 1/\sqrt{6} \end{pmatrix} \begin{pmatrix} 24 & 0 & 0 \\ 0 & 4 & 0 \\ 0 & 0 & 0 \end{pmatrix} \begin{pmatrix} 1/\sqrt{3} & 1/\sqrt{2} & 1/\sqrt{6} \\ 1/\sqrt{3} & 0 & -2/\sqrt{6} \\ 1/\sqrt{3} & -1/\sqrt{2} & 1/\sqrt{6} \end{pmatrix}^{-1}$$

つまり、

$$\begin{pmatrix} 1 & 2 & 3 \\ 3 & 2 & 1 \end{pmatrix} = \begin{pmatrix} 1/\sqrt{2} & -1/\sqrt{2} \\ 1/\sqrt{2} & 1/\sqrt{2} \end{pmatrix} \begin{pmatrix} 2\sqrt{6} & 0 & 0 \\ 0 & 2 & 0 \end{pmatrix} \begin{pmatrix} 1/\sqrt{3} & 1/\sqrt{3} & 1/\sqrt{3} \\ 1/\sqrt{2} & 0 & -1/\sqrt{2} \\ 1/\sqrt{6} & -2/\sqrt{6} & 1/\sqrt{6} \end{pmatrix}$$

と特異値分解できる。

2 確率・統計

2.1 条件付き確率

条件付き確率 $P(Y = y|X = x)$ とは、ある事象 $X = x$ が与えられた下で $Y = y$ となる確率である。 $X = x$ と $Y = y$ が同時に発生する確率を同時確率 $P(Y = y, X = x)$ とすると、式 20 と表せる。つまり、同時確率を $X = x$ となる確率 $P(X = x)$ で割った値となる。

$$P(Y = y|X = x) = \frac{P(Y = y, X = x)}{P(X = x)} \quad (20)$$

2.2 ベイズ則

式 20 同様に、ある事象 $Y = y$ が与えられた下で $X = x$ となる確率 $P(X = x|Y = y)$ は 21 と表せる。

$$P(X = x|Y = y) = \frac{P(Y = y, X = x)}{P(Y = y)} \quad (21)$$

つまり、式 20, 21 から式 22 が導かれる。

$$P(Y = y|X = x) = \frac{P(X = x|Y = y)P(Y = y)}{P(X = x)} \quad (22)$$

式 22 をベイズ則（ベイズの定理）という。

ベイズ則を利用することで、結果から原因を推定することができる。例えば、飴玉と子供たちの笑顔について以下の関係があるとする。

- ある街の子どもたちが飴玉をもらえる確率は $1/4$
- 街の子どもたちが笑顔でいる確率は $1/3$
- 飴玉をもらおうと子供たちが笑顔になる確率は $1/2$

ここで、笑顔な子どもがいたとしてその子が飴玉をもらっている確率は、ベイズ則から $1/2 \times 1/4 \div 1/3 = 3/8$ と求まる。よって、「飴玉をもらおうと子供たちが笑顔になった」という結果から、笑顔の原因が飴玉である確率が $3/8$ と求められ、約半分程度飴玉が理由であると推定できた。

2.3 期待値と分散

事象 $X = x_1, x_2, \dots, x_n$ に対して、確率変数 $f(X) = f(x_1), f(x_2), \dots, f(x_n)$ 、確率 $P(X) = P(x_1), P(x_2), \dots, P(x_n)$ があったとする。このとき、確率変数 f に対する期待値 $E(f)$ は式 23 と表せる。すなわち、期待値とは確率変数の平均の値といえる。

$$E(f) = \sum_{k=1}^n P(X = x_k) f(X = x_k) \quad (23)$$

一方、データの散らばり具合を表す分散 $Var(f)$ は式 24 と表せる。

$$Var(f) = \sum_{k=1}^n P(X = x_k) (f(X = x_k) - E(f))^2 = E(f^2) - (E(f))^2 \quad (24)$$

さらに、2つの事象系列 $X = x_1, x_2, \dots, x_n, Y = y_1, y_2, \dots, y_n$ に対する確率変数 f, g の傾向を表す共分散 $Cov(f, g)$ は式 25 と表せる。ここで、共分散が正の値を取れば2つの確率変数は似た傾向を、負の値を取れば逆（一方の確率が増加すれば、もう一方は減少する）の傾向にあるといえる。

$$Cov(f, g) = \sum_{k=1}^n P(X = x_k) (f(X = x_k) - E(f))(g(Y = y_k) - E(g)) = E(fg) - E(f)E(g) \quad (25)$$

2.4 様々な確率分布

2.4.1 ベルヌーイ分布

ベルヌーイ分布とは、確率 p で 1 を、確率 $q = 1 - p$ で 0 をとる確率分布のことである。つまり、結果が 2 つしかない試行の確率分布である。例えば、結果が表と裏しかないコイントスなどである。

2.4.2 マルチヌーイ分布

マルチヌーイ分布とは、ベルヌーイ分布を 2 つ以上の結果にまで拡張した確率分布である。例えば、6 面あるサイコロを回す試行などである。

2.4.3 二項分布

二項分布 $P(k|p, n)$ とは、試行回数 n と成功率 p に対して、成功回数 k の確率を表す確率分布である。ベルヌーイ分布の多試行版ともいえる。式 26 で表せる。

$$P(k|p, n) = {}_n C_k p^k (1 - p)^{n-k} \quad (26)$$

2.4.4 ガウス分布（正規分布）

ガウス分布とは、平均を中心に左右対称の連続型の確率分布であり、正規分布とも呼ばれる。社会現象など様々な分野で現れることが多く、機械学習やパターン認識でも重要な役割を持つ。

3 情報理論

3.1 自己情報量

自己情報量とは、事象がもつ情報量（事象が起こる珍しさ）のことである。つまり、確率という言葉を用いれば以下の 2 つが成り立つ。

1. 確率が高いほど、自己情報量は小さくなる
2. 事象 x かつ y が起きた時の自己情報量は、事象 x と y の自己情報量の加算である

よって、事象 x の自己情報量 $I(x)$ として、対数 \log を用いた式 27 が考えられる（底はなんでもよいが、以後ネイピア数とする）。

$$I(x) = -\log P(x) \quad (27)$$

3.2 シャノンエントロピー

シャノンエントロピー $H(X)$ とは、自己情報量の期待値である。式 28 で表せる。

$$H(X) = E(I(x)) = -\sum_{k=1}^n P(x_k) \log P(x_k) \quad (28)$$

3.3 KL ダイバージェンス

KL ダイバージェンス $D_{\text{KL}}(P||Q)$ とは、同じ事象・確率変数における異なる確率分布 P, Q の違いを表す値であり、式 29 で表せる。

$$D_{\text{KL}}(P||Q) = \sum_{k=1}^n P(x_k) \log \frac{P(x_k)}{Q(x_k)} \quad (29)$$

機械学習では真の確率分布 $P(x)$ が複雑な場合、よく知っている $Q(x)$ で近似して考えるアプローチが取られており、その際に「 $Q(x)$ は $P(x)$ を近似できているか」を表す指標として KL ダイバージェンスが用いられている。

3.4 交差エントロピー

交差エントロピー $H(P, Q)$ とは、KL ダイバージェンス同様に 2 つの確率分布 P, Q の違いを表す値であり、式 30 で表せる。

$$H(P, Q) = - \sum_{k=1}^n P(x_k) \log Q(x_k) \quad (30)$$

交差エントロピーは、機械学習の損失関数などでよく用いられている。